

2장 공공 실시간 데이터는 어떻게 망가지는가

2주차 · 공공 데이터 품질

- ☐ 1장에서 데이터가 모델까지 가는 길을 봤다면, 이 장은 그 길에 실제로 흐르는 **공공 실시간 데이터**를 들여다봄
 - ☐ 어떤 속도로 들어오는지 다룸
 - ☐ 어디가 망가지는지 다룸
 - ☐ “값이 변했다”를 언제 문제로 볼지 판단하는 방법을 다룸
- ☐ 이 장의 수치는 서울 40개 측정소의 실제 대기질 응답을 두 시각에 받아 비교한 결과임

1. 오늘의 질문

- ☐ “실시간”이라는 말은 항상 같은 속도를 뜻할까?
- ☐ 실시간 데이터에서 가장 흔히 망가지는 곳은 어디일까?
- ☐ 22시에 측정된 값을 22시 30분에 받았다면, 이것은 몇 시의 데이터일까?
- ☐ 데이터가 변했다는 것을 어떻게 알아차리고, 언제 문제로 볼까?

2. 우편물 처리소로 보는 이 장

- ☐ 이 장의 네 주제는 우편물 처리소에 하나씩 대응함

우편물 처리소	실시간 데이터
편지가 들어오는 방식이 다르다 — 매일 조금씩, 명절에 폭증, 정해진 시간에 한 묶음	유입 패턴이 유형마다 다르다
같은 편지가 두 번 오고, 늦게 오고, 주소가 비어 있고, 봉투 규격이 바뀐다	중복·지연·결측·스키마 변경
소인 날짜(부친 날)와 도착 날짜는 다르다	이벤트 시간과 처리 시간
해가 바뀌며 오가는 우편물의 종류 구성이 달라진다	데이터 드리프트

- ☐ 특히 세 번째 대응이 이 장의 핵심임
 - ☐ “언제 부쳤는가”로 세는 것과 “언제 받았는가”로 세는 것은 다른 통계를 만든다.
 - ☐ 우편물은 사람이 소인을 눈으로 확인함
 - ☐ 데이터에서는 시스템이 무엇을 기준으로 셀지 코드로 정해 놓아야 함

3. “실시간”은 하나의 속도가 아니다

- 실시간 데이터라고 하면 초 단위로 쏟아지는 장면을 떠올리기 쉬움
 - 공공 데이터는 그렇지 않음
 - 들어오는 방식이 네 갈래로 갈림

유입 패턴	어떻게 들어오는가	공공 예
지속 유입	업무시간 내내 대체로 일정한 속도	접수되는 민원
버스트	평소 조용하다 특정 사건에 폭증	재난 문자 발송 직후의 신고
고빈도	초 단위로 대량 유입	교통 센서 스트림
주기 갱신	정해진 간격으로 한 묶음씩	분·시 단위 환경 측정값

- 이 구분은 이름표를 붙이려는 것이 아니라 **설계를 미리 갈라 두려는 것이다**
 - 평균 유입량에 맞춰 용량을 잡으면 버스트가 오는 날 시스템이 포화됨
 - 반대로 한 시간마다 갱신되는 주기 갱신 데이터를 1분마다 호출하면 API 호출 한도만 소진되고 새 데이터는 없음
- 한 가지 축으로 정리하면 **사람이 입력하는가, 기계가 입력하는가**
 - 민원처럼 사람이 자유 텍스트로 입력하는 데이터
 - 필드가 비고 표현이 제각각임
 - 본문에 개인정보가 섞임
 - 교통·환경 센서처럼 기계가 보내는 데이터
 - 개인정보 위험은 낮음
 - 장비 오작동과 통신 장애가 결측의 주된 원인임
- 같은 사건이 유형에 따라 다르게 나타남
 - 초미세먼지 비상저감조치가 발령된 날, 환경 데이터는 값의 수준만 오르고 유입 구조는 그대로임
 - 민원은 “매연 차량 신고” 같은 유형의 비중이 늘어 분포가 바뀜
 - 안내 문자 발송 직후 문의는 폭증함
 - 하나의 “폭증”에 세 가지 다른 대응이 필요하다

4. 네 가지가 반복해서 망가진다

- 실시간 데이터에서 품질 문제는 예외가 아니라 정상 상태에 가깝다
 - 반복해서 나타나는 것이 네 가지임
- **중복 — 안전장치의 부작용**
 - 같은 이벤트가 두 번 이상 들어옴
 - 대부분 버그가 아니라 유실을 막으려는 재시도의 결과임
 - 4장에서 처리를 커밋보다 앞세운 설계로 실험하면 프로그램이 크래시(crash)한 뒤 재시작할 때 **중복 10건**이 생김

- 민원 1건이 두 번 세어지면 “민원이 늘었다”는 잘못된 신호가 대시보드와 모델 입력에 그대로 들어감
- 막는 방법은 이벤트마다 고유 식별자를 붙이는 것임
 - 5장에서 직접 만들

□ 지연 — 늦게 도착하는 과거

- 이벤트가 발생 시각보다 늦게 도착함
- 이미 마감해 보고한 집계가 나중에 틀린 것이 됨
- 6장에서 허용 지연을 10분으로 두고 늦은 이벤트 두 건을 흘린 결과
 - 22:04에 발생한 것은 수용되어 집계가 3에서 4로 갱신됨
 - 21:49에 발생한 것은 폐기되어 폐기 건수가 0에서 1로 증가함
- 여기서 중요한 것은 비대칭임
 - 수용은 결과를 보면 확인됨
 - 폐기는 결과 어디에도 보이지 않는다.
 - 따로 세지 않으면 사라진 줄도 모름

□ 결측 — 값과 파생 필드는 따로 본다

- 있어야 할 값이 빈
- 그런데 결측을 데이터 전체 단위로만 세면 놓침
- 이 장의 실습에서 서울 40개 측정소 스냅샷을 보면 PM10 측정값(pm10Value)은 40개가 모두 채워져 있는데 그 값에서 계산되는 등급(pm10Grade)은 한 측정소에서 비어 있음
 - 값은 있는데 등급이 없음
- 결측 점검은 데이터 전체가 아니라 필드별로 해야 한다는 것이 이 관찰의 결론이다

□ 스키마 변경 — 죽지 않고 조용히 틀린다


- 필드가 추가·삭제되거나 타입이 바뀜
- 1장에서 본 침묵 실패가 여기서 다시 나옴
- 없는 필드를 찾으면 파서는 오류를 내지 않고 None 을 돌려줄 뿐임
 - 집계는 계속 돌면서 결측률만 조용히 100%가 됨
- 7장에서는 표준 코드 사전에 없는 표기를 비슷한 자치구에 억지로 끼워 맞추지 않고 **미매핑으로 분리해 보고함**
 - 건수 합이 맞지 않으면 배치 자체를 실패시킴

위험	운영에서 보이는 신호	최소 대응	실측이 나오는 장
중복	같은 이벤트가 반복 수신	고유 식별자로 중복 흡수	4장(중복 10건), 5장
지연	발생 시각과 수신 시각이 벌어짐	이벤트 시간 기준 집계, 폐기 건수 감시	6장, 14장
결측	필드별 결측률 증가	필드별·사유별로 나누어 집계	실습 2.1, 7장
스키마 변경	코드·단위·필드가 조용히 바뀜	스키마 검증, 변경 통지	7장

- 다섯 번째 위험인 **개인정보 유입**은 성격이 다르다
 - 민원 텍스트처럼 사람이 입력한 데이터에는 식별 가능한 값이 섞임
 - 수집한 뒤에 처리하려 하면 이미 로그와 백업에 퍼진 뒤라 되돌릴 수 없음
 - 그래서 마스킹은 수집 단계의 설계 조건이다
 - 접근 통제와 관련 법령은 13장과 16장에서 다룸

5. 이벤트 시간과 처리 시간

- **이벤트 시간**은 사건이 일어나거나 측정된 시각이다
- **처리 시간**은 시스템이 그 데이터를 받은 시각이다
 - 이벤트 시간과 처리 시간은 거의 항상 벌어짐
 - 네트워크 지연, 배치 갱신, 재전송, 원천의 게시 지연 때문임
- 공공 환경 데이터에는 구조적인 게시 지연이 있다
 - 22:00에 측정된 값이 22:00보다 늦게 게시됨
 - 그래서 “이것이 몇 시 데이터인가”는 내 컴퓨터의 시계가 아니라 **응답 안의 `dateTime` 값**으로 확인해야 함
- 처리 시간으로 집계하면 “언제 일어난 일인가”가 흐려짐
 - 구청이 22:00~23:00에 접수된 민원 40건을 처리해야 하는데 시스템 부하로 그중 15건이 23시 이후에 적재됐다고 하자
 - 처리 시간 기준 집계는 “22시대 25건”으로 보고함
 - 다음 배치가 그 수치로 인력을 정함
 - 22시대는 실제보다 적게, 23시대는 많게 배치되어 두 시간대가 모두 어긋남
 - 이벤트 시간 기준이었다면 40건이 온전히 22시대로 귀속됐을 것임



이벤트 시간과 처리 시간의 간극, 그리고 워터마크 판정

그림 2.1 이벤트 시간과 처리 시간의 간극, 그리고 워터마크(watermark) 판정

- 워터마크는 이 간극을 얼마나 허용할지 정한 시각 임계값이다
 - 도착이 워터마크 안이면 수용해 집계를 갱신함
 - 넘으면 폐기하고 폐기 건수만 올림
 - 4절에서 말한 비대칭이 그림에 그대로 나타남
 - 자세한 처리는 6장에서 직접 실행함
- 원칙은 하나다
 - 집계와 드리프트 판단은 이벤트 시간 기준으로 설계하고, 산출물에 어떤 시간을 썼는지 적어 둔다.

6. 데이터 드리프트 — 코드는 그대로인데 성능이 떨어진다

- 데이터 드리프트는 입력 데이터의 분포가 시간에 따라 변하는 현상이다
 - 모델은 학습 당시의 분포를 전제로 동작함
 - 입력 분포가 달라지면 코드가 한 줄도 바뀌지 않아도 성능이 떨어짐
 - 테스트는 코드를 고쳐야 돌지만 드리프트는 아무도 아무것도 고치지 않아도 옴
- 공공 데이터에서 드리프트를 부르는 원인은 네 갈래다
 - 정책 변화로 민원 유형 코드가 개편되면 분포가 바뀜
 - 계절성은 미세먼지·한파 민원처럼 매년 반복됨

- 외부 이벤트는 대형 재난처럼 일시적으로 폭증시킴
- 시스템 변경은 센서 교체나 API 변경으로 값의 범위와 결측 패턴을 바꿈
- 여기서 바로 반대 방향의 주의가 불음
 - 감지했다고 항상 경보를 올리면 안 된다.
 - 특히 계절성처럼 매년 반복되는 변화를 매년 "이상"으로 경보하면 알림에 무뎌져 진짜 경보까지 무시하게 됨
 - 예상되는 패턴은 경보가 아니라 모델에 반영할 조건으로 다루는 편이 옳음
- 한 가지 구분을 덧붙임
 - 데이터 드리프트는 입력 분포의 변화임
 - 개념 드리프트는 입력과 정답 사이 관계 자체의 변화임
 - 같은 민원 문장이라도 "긴급"의 기준이 바뀌면 입력은 그대로인데 정답이 달라짐

변화를 어떻게 재는가 — KS 검정

- 두 시점의 분포를 비교하는 방법으로 콜모고로프-스미르노프(Kolmogorov-Smirnov, KS) 2표본 검정을 쓴다
 - 두 표본의 누적분포 사이 최대 간격을 잴(통계량 D)
 - "두 표본이 같은 분포에서 나왔다"고 가정했을 때 그만큼 큰 간격이 우연히 나올 확률(p-value)을 돌려줌
- 해석에서 두 가지를 반드시 주의함
 - 이 두 가지가 시험에도 나옴
- 첫째, p-value는 "분포가 변했을 확률"이 아니다.
 - 귀무가설이 참일 때 이만큼의 차이가 우연히 나올 확률임
 - 그래서 p-value가 크다고 "두 분포가 같다"가 증명되지 않음
 - 정확한 진술은 "다르다고 볼 충분한 증거가 없다"이다
- 둘째, 결과는 표본 크기에 좌우된다.
 - 표본이 크면 사소한 차이도 유의해짐
 - 작으면 진짜 변화도 놓침
 - 실습의 표본은 측정소 40개로 작은 편임
 - 작은 변화를 애초에 잡아내기 어려운 크기라는 점을 결과와 함께 읽어야 함
- 두 주의를 합치면 원칙이 하나 나옴
 - 단일 지표만으로 판정하지 않는다.
 - 11장에서 같은 서울 PM10 데이터에 9일 간격 비교를 더한 결과
 - PSI(Population Stability Index)는 0.3324로 경보 구간에 들어감
 - KS는 여전히 유의하지 않음
 - 두 지표가 다른 결론을 내는 것이 지표 하나를 믿으면 안 되는 이유다

7. 실습 2.1~2.2 응답 EDA와 분포 변화 비교 (난이도 ★★☆☆☆)

실습 목표

- ☐ 에어코리아 응답의 측정소 레코드를 DataFrame으로 바꾸고, 결측을 **필드별로** 요약함
- ☐ 같은 변수(PM10)의 두 시각 분포를 KS 검정과 분위수로 비교함
 - "값은 변해도 분포 변화가 통계적으로 유의하지 않을 수 있다"를 실제 데이터로 확인함

실행 환경

- ☐ Python 3.10 이상,
`pandas · numpy · scipy · requests · matplotlib ( practice/chapter2/code/requirements.txt )`
- ☐ 입력은 저장된 스냅샷 파일이 기본값임
 - 실시간 호출은 `--live` 옵션으로 하되 `DATA_GO_KR_API_KEY` 가 필요함

실행 명령

```
cd practice/chapter2
pip install -r code/requirements.txt

# 2.1 파싱 + EDA
python3 code/2-1-parse-api.py

# 2.2 분포 변화 비교
python3 code/2-2-drift-visualize.py \
  --baseline data/input/airquality_seoul_2200.json \
  --current data/input/airquality_seoul_current.json \
  --col pm10Value
```

핵심 코드

```
# 2-1-parse-api.py - 결측 표기('-') 처리와 EDA
df = pd.DataFrame(items)                                # response.body.items
df[col] = pd.to_numeric(df[col].replace({"-": np.nan}), errors="coerce")
missing = {col: int(df[col].isna().sum()) for col in MEASURE_COLS}
```

```
# 2-2-drift-visualize.py - 두 시각의 분포를 KS 검정으로 비교
base, base_time = load_series(Path(baseline), col)      # 기준 스냅샷
curr, curr_time = load_series(Path(current), col)      # 현재 스냅샷
stat, p = ks_2samp_with_fallback(base, curr)           # 분포 동일성 검정
```

전체 코드는 `practice/chapter2/code/2-1-parse-api.py`, `practice/chapter2/code/2-2-drift-visualize.py` 참고

실행 결과 확인 사항

□ 서울 22:00 스냅샷(측정소 40개)과 22:00→23:00 비교 결과다(`ch2_eda_summary.json` , `ch2_drift_result.json`)

측정소 수: 40개

PM10: 최소 14, 최대 27, 평균 20.0, 중앙값 20.0 ($\mu\text{g}/\text{m}^3$)

결측: PM10 측정값(`pm10Value`) 결측 0건 — 그러나 등급(`pm10Grade`)은 1건 결측

PM10 등급 분포: 1등급(좋음) 28개, 2등급(보통) 11개, 결측 1개

KS 검정(22:00 vs 23:00): 통계량 0.175, p-value 0.579 ($\alpha=0.05 \rightarrow \text{drift_detected} = \text{False}$)

분위수 이동: 25%는 17 → 19, 75%는 22 → 23으로 소폭 상승(50% 중앙값은 20 → 20으로 동일)

표 2.4 PM10 분위수 비교(기준 22:00 vs 현재 23:00)

분위수	기준(22:00)	현재(23:00)
0%	14.0	14.0
25%	17.0	19.0
50%	20.0	20.0
75%	22.0	23.0
100%	27.0	27.0

- 실시간 데이터이므로 여러분의 값은 다르다
 - 확인할 것은 값이 아니라 판정 절차다
 - `p_value` 와 `alpha` 를 비교해 `drift_detected` 가 어떻게 정해지는지를 6절과 대조함
 - 그 판정을 어떻게 서술해야 맞는지를 6절과 대조함

8. 핵심 요약

- 1. “실시간”은 네 가지 유입 패턴으로 갈린다.
 - 지속 유입·버스트·고빈도·주기 갱신임
 - 이 구분이 처리량 산정과 호출 주기라는 구체적 설계 결정으로 이어짐
 - 평균에 맞춰 잡은 용량은 버스트가 오는 날 포화됨
- 2. 반복해서 망가지는 곳은 네 군데다.
 - 중복은 재시도의 부작용임

- 지연은 마감한 집계를 뒤집음
- 결측은 필드별로 봐야 보임
- 스키마 변경은 오류 없이 조용히 틀림
- 특히 지연에서 폐기된 건수는 결과 어디에도 나타나지 않으므로 따로 세야 함
- 3. 집계 기준은 이벤트 시간이다.
 - 처리 시간으로 세면 "언제 일어났는가"라는 질문의 답이 틀림
 - 22시대 민원 40건이 25건으로 보고되면 인력 배치가 두 시간대 모두 어긋남
 - 어떤 시간을 썼는지 산출물에 적어 둠
- 4. 드리프트는 아무것도 고치지 않아도 온다.
 - 정책 변화·계절성·외부 이벤트·시스템 변경이 원인임
 - 코드가 그대로여도 성능이 떨어짐
 - 다만 계절처럼 반복되는 변화를 매번 경보로 처리하면 진짜 경보까지 무시하게 됨
- 5. p-value가 크다고 "분포가 같다"가 아니다.
 - "다르다고 볼 충분한 증거가 없다"는 뜻임
 - 결과는 표본 크기에 좌우되므로 측정소 40개 정도의 작은 표본에서는 진짜 변화도 놓칠 수 있음
 - 그래서 KS 하나로 판정하지 않고 PSI 같은 다른 지표와 함께 봄

9. 과제

- 실습을 실행해 생성된 다음 두 파일을 LMS에 그대로 업로드한다
 - `practice/chapter2/data/output/ch2_eda_summary.json`
 - `practice/chapter2/data/output/ch2_drift_result.json`
- 이어서 두 가지를 각각 세 문장 이내로 쓴다

본인의 `p_value`와 `alpha`를 비교해 `drift_detected` 값이 왜 그렇게 나왔는지 판정 규칙으로 설명한다.

`drift_detected`가 `false`인 것을 "두 시점의 분포가 같음이 확인되었다"로 보고하면 왜 틀린 서술인지, 본인의 `baseline_n` 값을 근거로 쓴다.

- 수업일 포함 7일 이내에 제출한다

10. 더 알아보기

- 이 장에서 다루지 않은 내용은 실무교재 `lecture/docs/chapter2.md`에 있다
- 데이터 관측성 — 신선도·양·스키마·분포·계보를 하나의 감시 체계로 묶는 관점: `lecture/docs/chapter2.md §2.2`
- 드리프트의 시간적 양상 — 급격·증분·점진·재발의 구분과 대응: §2.4
- 민간 현장의 감시 지표 — skew 분포(p50·p95·p99), 지연 이벤트 비율, 재학습 트리거 빈도: §2.3~§2.4

□ **개인정보와 법령** — 개인정보 보호법 적용 범위와 인용 시 주의: §2.2 (13장·16장에서 본격적으로 다룬다)