

4주차 과제 제출 답안

AI 데이터개발과 MLOps | 전영준 / 202373020

1. B의 유실과 C의 중복, 커밋 시점의 차이

전달 실험 B에서 생산 30건 중 고유 처리 10건이므로 유실은 20건이다. 배치의 오프셋을 먼저 커밋하고 10건만 처리한 뒤 장애가 발생하여, 재시작한 소비자가 이미 커밋된 미처리 이벤트를 다시 읽지 못했다. 전달 실험 C에서는 생산 30건에 대해 처리 기록 40건, 고유 이벤트 30건으로 중복은 10건이고 유실은 0건이다. 10건을 처리한 뒤 커밋 전에 종료하여, 재시작 시 이미 처리한 이벤트까지 다시 수신했기 때문이다.

2. 제약 없는 삽입과 UPSERT의 행 수 차이

중복 제거 실험 A의 제약 없는 삽입은 40행이고 C의 UPSERT는 30행으로, 차이는 10행이다. 이는 at-least-once에서 처리 후 커밋 전 장애로 이미 처리한 이벤트를 다시 받은 10건의 재수신 중복과 같은 유형에 대응한다. 같은 event_id에 대한 PRIMARY KEY 제약과 UPSERT가 새 업무 행을 만들지 않고 seen_count와 last_seen_at을 갱신하므로, 고유 이벤트 수만큼의 행만 유지된다. 중복 제거 입력은 교수자 제공 Kafka 장애 실험 스냅샷을 이번 재실행한 것이며, 이번 전달 실험 C의 처리 파일 자체를 입력으로 사용한 것은 아니다.

3. 같은 업무 상태 지문과 다른 총 관찰 수

중복 제거 실험 C와 D의 업무 상태 지문은 모두 eed1522a7ca844bd이고 행 수는 30행으로 같다. 이 코드의 업무 상태 지문은 event_id, partition, offset, first_seen_at을 event_id 순으로 정렬해 계산하며, 전체 스트림을 다시 처리해도 이 필드는 바뀌지 않는다. 반면 총 관찰 수는 C의 40에서 D의 80으로 증가한다. 40건을 한 번 더 리플레이하면서 seen_count를 매번 1씩 더하고 last_seen_at에는 해당 입력의 관찰 시각을 대입하기 때문이다. 따라서 업무 상태는 맥동하게 유지되고, 전달 입력은 반복 처리를 기록한다. 같은 스냅샷을 재생하므로 last_seen_at의 최종 값까지 반드시 더 늦어지는 것은 아니다.

실행 근거: 원본 생산·소비·커밋·장애 코드 실행. 전달 실험은 실제 Kafka 3.9.1 브로커, 중복 제거 실험은 제공 스냅샷의 SQLite 재실행. 강의 Docker 대신 Windows Java 환경 사용. 파일 잠금 회피를 위해 보조 실행기로 시나리오마다 신규 토픽 생성. 두 JSON을 함께 제출.